
Graphes de Patients et Représentations Latentes

Une exploration personnelle de l'IA appliquée à l'aide au diagnostic médical

SYOUD Walid

Ingénieur IA & Data Science

Avril 2026

Ce rapport documente une exploration personnelle menée dans le cadre de mon intérêt pour les applications de l'IA en médecine. Il ne prétend pas à l'exhaustivité scientifique d'un article de recherche, mais rend compte honnêtement d'une démarche d'apprentissage actif : ce que j'ai compris, ce que j'ai implémenté, les notions que je souhaite approfondir, et ce que cette expérience m'a appris sur ce domaine qui me passionne.

Dataset utilisé : PTB-XL (PhysioNet), 1 000 ECG réels de patients

Table des matières

1	Pourquoi ce projet	3
2	Le problème que j'ai voulu explorer	3
2.1	Comment un médecin raisonne	3
2.2	La donnée choisie : les signaux ECG	4
3	L'approche : des signaux aux graphes	6
3.1	Le défi de la haute dimensionnalité	6
3.2	L'auto-encodeur : apprendre à résumer	6
3.3	Pourquoi 64 valeurs ? Comprendre un vecteur d'embedding	7
3.4	L'architecture CNN 1D : pourquoi des convolutions sur le signal	7
3.5	La notion de batch	8
4	L'entraînement : apprendre à partir des données	8
4.1	Séparation train/test : une règle fondamentale	8
4.2	Comment l'entraînement s'est déroulé	9
4.3	L'early stopping : savoir s'arrêter au bon moment	10
5	Du résumé au graphe : connecter les patients	10
5.1	Extraire les embeddings	10
5.2	Mesurer la similarité : la similarité cosinus	11
5.3	Construire le graphe K-NN	11
6	Identifier les prototypes et les cas atypiques	12
6.1	La représentativité : trouver les cas typiques	12
6.2	L'atypicité : détecter les cas inhabituels	13
7	Résultats et visualisation	13

7.1	La visualisation UMAP	13
7.2	Les résultats chiffrés	14
8	Ce que je retiens de cette exploration	16
8.1	Ce que j'ai vraiment compris	16
8.2	Les notions que je souhaite approfondir	17
8.3	Ce que cette expérience m'a appris sur moi	17
8.4	Les limites de ce travail et les extensions naturelles	17
9	Conclusion	18

Pourquoi ce projet

Ingénieur en intelligence artificielle depuis plusieurs années, j'ai construit mon expertise dans des environnements industriels exigeants : d'abord chez Stellantis sur l'analyse de données capteurs embarqués, puis chez Inter Mutuelles Assistance sur des solutions IA déployées en production. Ce parcours m'a permis de maîtriser l'ensemble du cycle de vie des projets data, de la collecte des données jusqu'au monitoring des modèles en production.

Dès le départ, mon ambition a toujours été d'appliquer ces compétences à des domaines à fort impact. Après une première expérience dans l'industrie automobile et le secteur de l'assistance, il m'est apparu naturel d'orienter ma trajectoire vers la médecine et la biologie, deux domaines où l'IA peut avoir des conséquences directes et profondes sur la vie des gens. J'ai donc commencé à enrichir mon profil dans cette direction : certifications spécialisées, développement d'une plateforme personnelle d'aide au diagnostic appelée Medicare, et exploration active de projets de recherche appliquée.

Ce projet sur les graphes de patients s'inscrit dans cette démarche. Le sujet m'a attiré pour une raison très concrète : l'idée qu'un algorithme puisse aider un médecin à ne pas rater un cas rare, à retrouver des patients similaires dans son historique, à détecter automatiquement une situation inhabituelle méritant une attention particulière. Un diagnostic raté peut coûter une vie. Un outil qui aide à en éviter un seul justifie largement l'effort.

Ce projet m'a aussi permis de vérifier quelque chose d'important : est-ce que ce type de travail me plaît vraiment ? Suis-je à l'aise sur ces problématiques à l'interface de l'informatique, des mathématiques et de la biologie ? La réponse est oui, et j'espère que ce rapport le montre.

Le problème que j'ai voulu explorer

Comment un médecin raisonne

Quand un médecin expérimenté examine un patient, il ne part pas de zéro. Il compare mentalement la situation à des cas qu'il a déjà vus : *"ce profil ressemble à un patient que j'ai eu il y a deux ans, qui s'est avéré avoir une arythmie"*, ou encore *"je n'ai jamais vu ça, ce cas est vraiment inhabituel, il faut creuser"*. Ce raisonnement par analogie et par comparaison est au cœur de l'expertise clinique.

C'est précisément ce mécanisme que j'ai voulu explorer à travers ce projet : peut-on construire, à partir de données médicales réelles, une structure mathématique qui capture ces relations de

similarité entre patients ? Peut-on identifier automatiquement les cas "typiques" qui servent de références, et les cas "atypiques" qui méritent une attention particulière ?

La donnée choisie : les signaux ECG

Pour explorer cette idée, j'avais besoin de données médicales réelles, accessibles, et suffisamment riches pour être intéressantes. Mon choix s'est porté sur les électrocardiogrammes (ECG) du dataset PTB-XL, disponible librement sur PhysioNet.

Un ECG enregistre l'activité électrique du cœur. Il est capté simultanément sur 12 "dérivations", soit 12 électrodes placées à différents endroits du corps, qui donnent 12 "vues" différentes de ce qui se passe dans le cœur. Chaque enregistrement dure 10 secondes à une fréquence de 100 Hz, ce qui donne 1 000 points de mesure par dérivation, soit **12 000 valeurs numériques** par patient.

Caractéristique	Valeur
Dataset	PTB-XL (PhysioNet)
ECG disponibles au total	21 799
ECG utilisés dans ce projet	1 000
Durée par enregistrement	10 secondes
Fréquence d'échantillonnage	100 Hz
Nombre de dérivations	12
Valeurs par patient	12 000

TABLE 1 – Caractéristiques du dataset PTB-XL utilisé

Le dataset contient des ECG annotés par des cardiologues experts, couvrant une grande diversité de pathologies cardiaques : infarctus du myocarde, arythmies, hypertrophies ventriculaires, blocs de branche, et bien d'autres. C'est une référence internationale en cardiologie numérique, ce qui en fait un choix solide pour une exploration sérieuse.




FIGURE 1 – Démographie des 1 000 patients utilisés. Distribution de l'âge (moyenne : 61 ans) et répartition équilibrée hommes/femmes.




FIGURE 2 – Exemple d'ECG 12-dérivations extrait du dataset PTB-XL. Chaque dérivation capture une vue différente de l'activité électrique du cœur sur 10 secondes à 100 Hz.

L'approche : des signaux aux graphes

Le défi de la haute dimensionnalité

Le premier problème auquel je me suis confronté est simple à formuler mais difficile à résoudre : comment comparer deux patients dont chacun est décrit par 12 000 valeurs numériques ?

Calculer directement une distance entre deux vecteurs de 12 000 dimensions est techniquement possible, mais c'est une très mauvaise idée. Dans des espaces de très haute dimension, les distances perdent leur sens : tout devient approximativement à la même distance de tout le reste, les patterns significatifs se noient dans le bruit, et les calculs deviennent prohibitivement coûteux. C'est ce qu'on appelle le *fléau de la dimensionnalité*, un problème classique en apprentissage automatique.

La solution que j'ai choisie d'explorer est celle des **représentations latentes** : plutôt que de comparer les signaux bruts, on apprend d'abord à les résumer en une représentation compacte et informative, puis on compare ces résumés. L'idée est qu'un bon résumé d'un ECG capture ce qui est essentiel (le rythme cardiaque, la morphologie des ondes, les anomalies éventuelles) sans garder les 12 000 valeurs brutes.

L'auto-encodeur : apprendre à résumer

L'outil que j'ai utilisé pour produire ces résumés est un **auto-encodeur**. C'est un type de réseau de neurones avec une architecture particulière, en forme de sablier : il prend en entrée un signal complet (12 000 valeurs), le compresse progressivement vers un vecteur très petit (64 valeurs), puis tente de le reconstruire tel quel en sortie.

Intuition : le sablier de l'information

Imaginez qu'on vous demande de résumer un livre de 500 pages en une fiche de 10 lignes, puis de réécrire le livre à partir de cette fiche seulement. Pour que la réécriture soit fidèle, votre fiche doit capturer l'essentiel (les personnages principaux, l'intrigue, le ton) et non des détails anecdotiques. C'est exactement ce que fait l'auto-encodeur avec les signaux ECG : il apprend à écrire des "fiches" (les embeddings) qui permettent de reconstruire le signal original aussi fidèlement que possible.

La partie qui compresse est appelée **l'encodeur**, et la partie qui reconstruit est appelée **le décodeur**. Ce qui m'intéresse, c'est uniquement l'encodeur : une fois entraîné, je l'utilise pour transformer chaque ECG en son "résumé" de 64 valeurs, qu'on appelle son **embedding**.

Pourquoi 64 valeurs ? Comprendre un vecteur d'embedding

Le choix de 64 dimensions pour l'embedding mérite qu'on s'y arrête, car c'est une notion qui m'a pris du temps à appréhender intuitivement.

Concrètement, un vecteur de 64 dimensions c'est simplement une liste de 64 nombres réels. Par exemple : $[0.23, -1.47, 0.89, 0.12, \dots]$. Chacun de ces 64 nombres encode une caractéristique abstraite du signal ECG, pas forcément interprétable directement par un humain, mais mathématiquement significative.

Intuition : les coordonnées GPS du patient

Pensez à une carte géographique. Pour localiser une ville, vous avez besoin de deux nombres : latitude et longitude. Deux villes proches géographiquement ont des coordonnées proches. L'embedding fait la même chose mais dans un espace de 64 dimensions : deux patients avec des ECG similaires auront des embeddings proches dans cet espace. La distance entre deux embeddings devient une mesure de similarité entre deux patients.

Pourquoi 64 et pas 10 ou 1000 ? C'est un compromis. Trop peu de dimensions et on perd de l'information importante. Trop de dimensions et on ne compresse pas assez. 64 est une valeur couramment utilisée dans la littérature en deep learning (les modèles comme ResNet et BERT utilisent des dimensions similaires), et elle représente ici un taux de compression de 187 fois ($12\,000 \rightarrow 64$).

L'architecture CNN 1D : pourquoi des convolutions sur le signal

Pour construire l'encodeur, j'ai utilisé une architecture **CNN 1D**, un réseau de neurones convolutif adapté aux séries temporelles. La convolution 1D est une opération mathématique qui "glisse" un petit filtre le long du signal et détecte des patterns locaux.

Intuition : chercher des patterns dans le signal

Un ECG contient des formes caractéristiques récurrentes : l'onde P (dépolariation auriculaire), le complexe QRS (contraction ventriculaire), l'onde T (repolarisation). Une convolution 1D avec un filtre approprié va "s'allumer" chaque fois qu'elle rencontre l'une de ces formes, quelle que soit sa position dans le signal. C'est comme passer un gabarit sur une feuille pour trouver toutes les occurrences d'une forme donnée.

L'encodeur que j'ai utilisé est composé de quatre blocs successifs, chacun comprenant :

Des couches de convolution qui détectent des patterns de plus en plus abstraits. Le premier bloc détecte des patterns simples (bords, variations locales), les blocs suivants combinent ces patterns pour reconnaître des structures plus complexes (morphologie d'une onde, rythme global). Le nombre de filtres augmente progressivement : 32, 64, 128, puis 256. Plus on monte dans le

réseau, plus les représentations sont abstraites et riches.

Du MaxPooling après chaque bloc : c'est une opération de sous-échantillonnage qui divise la longueur du signal par 2 à chaque étape. Concrètement, au lieu de garder toutes les valeurs, on garde seulement la valeur maximale dans chaque fenêtre de 2 points. Cela réduit progressivement la taille du signal tout en gardant les informations les plus saillantes, un peu comme zoomer en arrière sur une image pour n'en voir que les grandes structures.

De la Batch Normalization : c'est une technique de stabilisation de l'entraînement. Pendant l'apprentissage, les valeurs qui circulent dans le réseau peuvent varier énormément d'un lot à l'autre, ce qui rend la convergence instable. La Batch Normalization recadre ces valeurs à chaque couche pour qu'elles restent dans une plage raisonnable. Je l'ai découvert en faisant ce projet. Je ne connaissais pas cette technique auparavant et comprendre son rôle m'a pris quelques lectures.

Du Dropout à 20% : pendant l'entraînement, 20% des connexions du réseau sont désactivées aléatoirement à chaque passage. Cela oblige le réseau à ne pas trop dépendre d'un chemin particulier et à apprendre des représentations plus robustes. C'est une technique de régularisation classique pour éviter le surapprentissage.

La notion de batch

Pendant l'entraînement, on ne présente pas les 800 ECG au réseau en une seule fois, ce serait trop lourd en mémoire et rendrait les mises à jour des poids très instables. On les présente par petits groupes appelés **batches**. Ici j'ai utilisé des batches de 32 ECG.

Intuition : apprendre par petits groupes

C'est comme un étudiant qui révise ses 800 fiches de cours. Plutôt que de tout lire d'une traite, il les passe en revue par paquets de 32, fait un bilan après chaque paquet, et ajuste sa compréhension. Après avoir vu tous les paquets, il a fait une "époque". L'entraînement fait pareil : à la fin de chaque batch, les poids du réseau sont mis à jour, puis on passe au batch suivant.

L'entraînement : apprendre à partir des données

Séparation train/test : une règle fondamentale

Avant toute chose, j'ai séparé mes 1 000 patients en deux groupes distincts : 800 pour l'entraînement (le *train set*) et 200 que je n'ai pas touchés pendant l'entraînement (le *test set*).

Cette séparation est une règle fondamentale en apprentissage automatique, et je veux expliquer

pourquoi elle est si critique, surtout en contexte médical.

Si on évalue un modèle sur les données qui ont servi à l'entraîner, on ne sait pas si le modèle a vraiment *appris* quelque chose de général, ou s'il a simplement *mémorisé* les exemples vus. Un modèle qui mémorise peut obtenir 100% de précision à l'entraînement et être complètement inutile sur de nouveaux patients. En médecine, un outil qui fonctionne bien sur les données connues mais échoue sur de nouveaux cas pourrait être dangereux.

Le principe de la séparation est donc : le modèle ne voit jamais les 200 patients test pendant l'entraînement. Ces patients simulent des nouveaux arrivants à l'hôpital, que le système n'a jamais rencontrés. L'évaluation sur ce jeu de test donne une mesure honnête de la capacité de généralisation.

Dans ce projet, j'ai poussé cette logique encore plus loin : le graphe de patients a été construit **uniquement** sur les 800 patients du train set. Les 200 patients test ont ensuite été évalués comme de vrais nouveaux arrivants : leur embedding est calculé avec l'auto-encodeur entraîné, puis on cherche leurs voisins les plus proches dans le graphe existant.

Comment l'entraînement s'est déroulé

L'auto-encodeur a été entraîné sur les 800 ECG du train set. À chaque époque, voici ce qui se passe : le réseau prend un batch de 32 ECG, les compresse en embeddings de 64 dimensions via l'encodeur, puis tente de les reconstruire via le décodeur. L'erreur de reconstruction, c'est-à-dire la différence entre le signal original et le signal reconstruit, est mesurée par la **fonction de perte MSE** (Mean Squared Error, erreur quadratique moyenne). Cette erreur est ensuite propagée en sens inverse dans le réseau (c'est la rétropropagation) pour ajuster les poids et réduire l'erreur au prochain passage.

J'ai utilisé l'optimiseur **Adam**, qui est aujourd'hui le standard en deep learning. Contrairement à la descente de gradient classique où tous les poids sont mis à jour avec le même taux d'apprentissage, Adam adapte ce taux individuellement pour chaque poids en fonction de l'historique de ses mises à jour. En pratique, il converge plus rapidement et est beaucoup moins sensible aux choix de configuration.

Paramètre	Valeur
Patients d'entraînement	800 (80%)
Patients de test	200 (20%)
Taille des batches	32
Époques maximales	50
Optimiseur	Adam (lr = 0.001)
Fonction de perte	MSE
Early stopping (patience)	15 époques

TABLE 2 – Paramètres d'entraînement

L'early stopping : savoir s'arrêter au bon moment

Un mécanisme que j'ai trouvé particulièrement élégant est l'**early stopping**. Plutôt que d'entraîner le modèle pendant exactement 50 époques, on surveille l'erreur sur le jeu de validation à chaque époque. Si cette erreur ne s'améliore plus pendant 15 époques consécutives, on arrête l'entraînement et on restaure les poids de la meilleure époque.

Dans mon cas, l'entraînement s'est arrêté à la 16^{ème} époque. C'est un bon signe : le modèle a convergé rapidement, et l'erreur de validation (1.0007) est très proche de l'erreur d'entraînement (0.9985). Cette proximité entre les deux courbes indique qu'il n'y a pas de surapprentissage. Le modèle a bien généralisé.




FIGURE 3 – Courbes d'apprentissage de l'auto-encodeur (loss MSE et MAE). La convergence rapide en 16 époques et la proximité des courbes train/validation confirment un apprentissage sain, sans surapprentissage.

Du résumé au graphe : connecter les patients

Extraire les embeddings

Une fois l'auto-encodeur entraîné, j'ai utilisé uniquement la partie encodeur pour transformer chacun des 1 000 ECG en son vecteur de 64 dimensions. À cette étape, chaque patient n'est plus décrit par 12 000 valeurs brutes mais par un vecteur compact qui capture l'essence de son signal cardiaque.

Mesurer la similarité : la similarité cosinus

Pour construire le graphe, il faut définir ce que "être similaire" veut dire mathématiquement. J'ai utilisé la **similarité cosinus**, définie comme suit :

$$\text{similarité}(p_i, p_j) = \frac{e_i \cdot e_j}{\|e_i\| \cdot \|e_j\|} \quad (1)$$

où e_i et e_j sont les embeddings de deux patients. Le résultat est un nombre entre 0 et 1 : 1 signifie que les deux vecteurs pointent dans la même direction (patients très similaires), 0 signifie qu'ils sont perpendiculaires (aucune relation).

Pourquoi cosinus plutôt qu'eulidien ?

La distance euclidienne mesure l'écart absolu entre deux points, elle est sensible à la "taille" des vecteurs. La similarité cosinus mesure l'angle entre deux vecteurs, elle est sensible à leur "direction". Pour des embeddings appris, ce qui compte c'est la direction (le profil du patient), pas la magnitude (l'intensité du signal). Deux ECG enregistrés avec des amplitudes différentes mais des patterns identiques auront des cosinus proches de 1, même si leur distance euclidienne est grande.

Construire le graphe K-NN

Le graphe est construit selon le principe du **K plus proches voisins** (K-NN) : pour chaque patient, on calcule sa similarité cosinus avec tous les autres patients du train set, puis on crée un lien avec ses 10 voisins les plus similaires ($k=10$).

Le résultat est un graphe de 800 nœuds et 5 748 connexions, avec un degré moyen de 14.37 (légèrement supérieur à 10 car les connexions sont non-dirigées : si A est voisin de B, B est aussi voisin de A). La similarité moyenne entre patients connectés est de 0.9989, signe que les connexions sont de très haute qualité.

Le choix de $k=10$ est un compromis classique : trop petit ($k=3$) fragmenterait le graphe en îlots isolés, trop grand ($k=50$) diluerait la notion de proximité. 10 est une valeur standard dans la littérature sur les graphes de similarité.




FIGURE 4 – Distribution des similarités cosinus entre patients connectés dans le graphe. La quasi-totalité des connexions ont une similarité supérieure à 0.98, avec une moyenne de 0.9989, signe que le graphe capture des relations de haute qualité.

En observant cette distribution, une question légitime se pose : pourquoi les similarités sont-elles si concentrées autour de 0.9989 ? En d'autres termes, pourquoi presque tous les patients connectés dans le graphe se ressemblent-ils autant dans l'espace latent ?

C'est une limite réelle de cette exploration que je veux nommer clairement. L'auto-encodeur a pu prendre un raccourci classique en apprentissage profond : plutôt que d'apprendre à vraiment différencier les patients selon leurs pathologies, il a appris une représentation "moyenne" des ECG, produisant des embeddings tous proches les uns des autres. Ce phénomène s'appelle l'effondrement des représentations, et il est fréquent avec les auto-encodeurs classiques.

Plusieurs pistes permettraient d'y remédier. La première, simple à tester, serait de réduire la dimension des embeddings de 64 à 16 ou 32, ce qui forcerait le modèle à vraiment choisir ce qui est discriminant. Une autre approche serait de passer à un auto-encodeur variationnel (VAE), qui ajoute une contrainte probabiliste forçant les embeddings à se disperser dans l'espace latent. Ces améliorations constituent des directions naturelles pour aller plus loin.

Identifier les prototypes et les cas atypiques

C'est la partie qui m'a le plus enthousiasmé, car elle fait le lien entre les mathématiques et le raisonnement clinique.

La représentativité : trouver les cas typiques

Un patient est dit **prototypique** s'il est entouré de nombreux patients similaires dans le graphe, c'est-à-dire s'il est au "centre" de son quartier. On calcule sa représentativité comme la moyenne des similarités cosinus avec ses 20 plus proches voisins :

$$\text{représentativité}(p_i) = \frac{1}{k} \sum_{j \in N_k(i)} \text{similarité}(p_i, p_j) \quad (2)$$

Un score élevé (proche de 1) signifie que ce patient a un profil ECG très standard, très représentatif de ce que le système a appris. En clinique, ces patients prototypiques pourraient servir de cas de référence pour l'enseignement ou le diagnostic : *"voici à quoi ressemble un infarctus typique"*.

Cette idée s'inspire de la **théorie des prototypes** en psychologie cognitive, développée par Eleanor Rosch dans les années 1970. Elle postule que les humains catégorisent les objets en les comparant à des exemplaires typiques plutôt qu'à des définitions abstraites. Un merle est un "meilleur exemple" d'oiseau qu'un pingouin, même si les deux sont des oiseaux. De la même façon, un ECG prototypique est un "meilleur exemple" de sa pathologie qu'un cas limite.

L'atypicité : détecter les cas inhabituels

L'atypicité est l'inverse de la représentativité : un patient atypique est isolé dans le graphe, peu similaire à ses voisins. On la calcule comme la distance moyenne aux voisins :

$$\text{atypicité}(p_i) = \frac{1}{k} \sum_{j \in N_k(i)} (1 - \text{similarité}(p_i, p_j)) \quad (3)$$

En clinique, un score d'atypicité élevé devrait déclencher une alerte : *"ce patient ne ressemble à aucun cas connu, une investigation approfondie est recommandée"*. C'est exactement le type de situation où un outil automatique peut aider un médecin à ne pas passer à côté d'une pathologie rare ou d'une présentation inhabituelle.

Résultats et visualisation

La visualisation UMAP

Avant de présenter les résultats chiffrés, il faut mentionner l'outil de visualisation utilisé : **UMAP** (Uniform Manifold Approximation and Projection). Les embeddings vivent dans un espace de 64 dimensions, impossible à visualiser directement. UMAP est un algorithme de réduction de dimensionnalité qui projette ces 64 dimensions en 2 dimensions tout en préservant au maximum la structure des données : les patients similaires dans l'espace 64D restent proches dans l'espace 2D.

Le graphique UMAP obtenu montre les 1 000 patients en 2D, avec les patients train en bleu et les patients test en rouge. Les deux nuages se mélangent naturellement, sans séparation artificielle, ce qui confirme que les deux groupes ont des profils similaires et que la séparation train/test a été faite correctement. Les prototypes (étoiles) et les cas atypiques (triangles) sont bien distribués dans les deux ensembles.




FIGURE 5 – Visualisation UMAP 2D des 1 000 patients. Train (bleu) et test (rouge) se mélangent naturellement. Les prototypes (étoiles) sont regroupés dans les zones denses, tandis que les atypiques (triangles) se trouvent en périphérie ou isolés, ce qui est cohérent avec leur définition.

Les résultats chiffrés

Métrique	Train (n=800)	Test (n=200)	Différence
Représentativité moyenne	0.9487	0.8963	5.53%
Atypicité moyenne	0.0513	0.1037	faible en valeur absolue
Prototypes identifiés	10	10	–
Atypiques identifiés	10	10	–

TABLE 3 – Comparaison des métriques entre train et test

Le résultat clé est la différence de **5.53%** en représentativité entre train et test. Cela signifie que les 200 nouveaux patients que le système n'avait jamais vus s'intègrent naturellement dans la structure du graphe, avec un profil de similarité très proche de celui des patients d'entraînement. Le système généralise bien.

L'atypicité test (10.37%) est légèrement supérieure à l'atypicité train (5.13%), ce qui est attendu : des patients que le système n'a jamais vus sont naturellement un peu plus "étrangers" que ceux sur lesquels il a appris. Mais la différence absolue reste faible (0.0524), ce qui confirme la robustesse de l'approche.




FIGURE 6 – Comparaison directe des métriques moyennes entre train et test. La faible différence (5.53% en représentativité) confirme que le graphe généralise bien aux nouveaux patients.




FIGURE 7 – Distributions des scores de représentativité et d'atypicité pour le train set (bleu) et le test set (rouge). Les distributions sont similaires, confirmant la bonne généralisation du système.

Ce que je retiens de cette exploration

Ce que j'ai vraiment compris

Au terme de ce projet, je pense avoir une compréhension solide du principe général : prendre des données complexes (ici des signaux ECG), apprendre à les résumer sous forme d'embeddings compacts via un auto-encodeur, puis exploiter ces résumés pour construire des structures de similarité entre patients. J'ai aussi compris pourquoi cette approche est particulièrement adaptée à l'aide au raisonnement clinique : elle formalise mathématiquement ce que les médecins font naturellement, à savoir raisonner par analogie et par comparaison de cas.

La partie traitement du signal (l'encodeur CNN 1D) me parle particulièrement, car elle rejoint mon expérience industrielle chez Stellantis sur l'analyse de signaux capteurs. Les concepts de convolution, de détection de patterns temporels, d'extraction de features. Je les avais déjà abordés

dans un contexte différent. Les appliquer à des signaux physiologiques m'a semblé naturel.

Les notions que je souhaite approfondir

Ce projet m'a donné envie d'aller plus loin sur plusieurs points précis. L'architecture détaillée de l'encodeur, notamment le rôle du GlobalAveragePooling1D et les justifications théoriques du choix du nombre de filtres, sont des aspects que j'ai compris intuitivement mais que je veux dériver plus rigoureusement. De même, les subtilités de l'optimisation adaptative avec Adam, ou les stratégies de réduction du learning rate comme ReduceLROnPlateau, sont des mécanismes que j'ai utilisés avec succès et dont je veux comprendre les fondements mathématiques plus en profondeur.

Ce sont précisément ces zones de progression qui m'enthousiasment. Chaque concept que j'ai effleuré dans ce projet représente une porte vers des questions plus fondamentales, que ce soit en théorie de l'apprentissage profond, en traitement du signal biomédical ou en théorie des graphes. C'est cet approfondissement progressif, au contact de chercheurs spécialisés, que je recherche.

Ce que cette expérience m'a appris sur moi

Ce projet m'a confirmé quelque chose d'important : travailler sur ces problématiques m'enthousiasme vraiment. Il y a eu des moments de frustration technique, des concepts à appréhender progressivement, des résultats à interpréter avec prudence. Mais à chaque étape, j'ai trouvé que la question de fond (comment aider un médecin à mieux diagnostiquer, comment rendre visible ce qui est invisible) était suffisamment motivante pour persévérer.

L'idée qu'un score d'atypicité élevé pourrait un jour alerter un praticien sur un cas qu'il aurait peut-être raté, ou que des patients prototypiques pourraient servir de cas de référence pour former les médecins de demain. Ces perspectives concrètes me donnent envie d'aller beaucoup plus loin.

Les limites de ce travail et les extensions naturelles

Ce projet reste une exploration avec des limites importantes que je veux nommer clairement.

D'abord, **l'échelle** : j'ai travaillé sur 1 000 patients sur les 21 799 disponibles dans PTB-XL. Passer à l'échelle complète changerait probablement les résultats de manière significative.

Ensuite, **la modalité unique** : je n'ai utilisé que les ECG. Un système cliniquement utile devrait intégrer d'autres types de données, comme l'imagerie médicale, les données biologiques, le texte clinique ou les données démographiques. La multimodalité est à la fois la plus grande difficulté et la perspective la plus excitante.

Enfin, **la validation clinique** est absente. Je n'ai aucun moyen de savoir si les patients que mon système identifie comme "similaires" sont réellement similaires du point de vue d'un cardiologue.

Cette validation par des experts du domaine serait indispensable avant tout usage réel.

Ce sont précisément ces extensions (multimodalité, robustesse, validation clinique, interprétabilité) qui constituent, à mes yeux, les vraies questions ouvertes et passionnantes de ce domaine.

Conclusion

Ce projet a été pour moi bien plus qu'un exercice technique. Il m'a permis de toucher du doigt quelque chose que je cherchais : une application de l'intelligence artificielle où chaque amélioration algorithmique peut se traduire en impact humain concret.

J'ai entraîné un auto-encodeur sur des données ECG réelles, extrait des représentations latentes, construit un graphe de similarité entre patients, et identifié automatiquement des cas typiques et atypiques avec une bonne capacité de généralisation. J'ai fait tout cela en comprenant ce que je faisais au niveau des principes, avec l'envie d'aller encore plus loin sur les fondements théoriques.

Ce rapport est une photographie honnête de là où j'en suis aujourd'hui : un ingénieur IA avec une vraie expérience industrielle, une appétence forte pour les problématiques médicales et biologiques, et une curiosité intacte pour les questions ouvertes de ce domaine. Ce n'est pas le portrait d'un expert accompli, mais celui d'un profil sérieux qui sait ce qu'il veut et qui a démontré sa capacité à s'emparer de sujets nouveaux avec méthode et enthousiasme.

Ce que j'aimerais par-dessus tout, c'est approfondir tous ces sujets aux côtés d'une équipe de recherche : comprendre les fondements que j'ai effleurés, explorer la multimodalité, confronter les résultats à des experts cliniciens, et contribuer à un vrai travail de recherche. Ce projet n'est pas une fin en soi. C'est le début d'une trajectoire que je veux poursuivre avec rigueur, curiosité et enthousiasme.